

Лабораторна робота №6

Наївний Байєс в Python

Мета роботи: набути навичок працювати з даними і опонувати роботу у Python з використанням теореми Байєса.

Завдання 1. Ретельно опрацювати теоретичні відомості:

Теорема Байєса дозволяє обчислити ймовірність гіпотези H за наявності певного доказу E . Формула має вигляд:

$$P(H|E) = P(E|H) \cdot P(H) / P(E)$$

де $P(H)$ — апіорна ймовірність, $P(H|E)$ — апостеріорна ймовірність, $P(E|H)$ — правдоподібність, $P(E)$ — повна ймовірність доказу.

Наївний байєсівський класифікатор вважає, що всі ознаки незалежні одна від одної. Це спрощує обчислення і дозволяє швидко виконувати класифікацію.

Основні типи наївного Байєса:

1. Gaussian Naive Bayes — використовується для неперервних числових даних.
2. Multinomial Naive Bayes — часто використовується для текстів і частот слів.
3. Bernoulli Naive Bayes — використовується для бінарних ознак: так/ні, 0/1.

Наївний Байєс застосовується у фільтрації спаму, класифікації текстів, прогнозуванні погоди, медичній діагностиці, рекомендаційних системах.

Завдання 3. Використовую данні з пункту 2 визначити відбудеться матч при наступних погодних умовах чи ні: Розрахунки провести з використанням Python.

варіант — **варіант 12:**

Outlook = Overcast

Humidity = High

Wind = Strong

Лістинг код :

```
# Лабораторна робота №6
# Завдання 3
```

					ЖИТОМИРСЬКА ПОЛІТЕХНІКА.25.125.12.000 –Лр.6						
Змн.	Арк.	№ докум.	Підпис	Дата							
Розроб.		Лук'яненко В. Я.			Звіт з лабораторної роботи №6			Літ.	Арк.	Акрушіє	
Перевір.		Маєвський О. В.								1	
Реценз.								ФІКТ, гр. КБ-23-1			
Н. Контр.											
Зав.каф.		Єфіменко А.А.									

```

# Наївний Байес: прогноз проведення матчу

# Загальна кількість прикладів
total = 14

# Кількість класів
yes = 9
no = 5

# Априорні ймовірності
P_yes = yes / total
P_no = no / total

# Варіант 12:
# Outlook = Overcast
# Humidity = High
# Wind = Strong

# Частотні значення з таблиці методички
P_outlook_yes = 4 / 9      # Overcast при Yes
P_outlook_no = 0 / 5      # Overcast при No

P_humidity_yes = 3 / 9    # High при Yes
P_humidity_no = 4 / 5    # High при No

P_wind_yes = 3 / 9       # Strong при Yes
P_wind_no = 3 / 5       # Strong при No

# Обчислення ненормалізованих ймовірностей
prob_yes = P_outlook_yes * P_humidity_yes * P_wind_yes * P_yes
prob_no = P_outlook_no * P_humidity_no * P_wind_no * P_no

print("Ненормалізована ймовірність Yes:", prob_yes)
print("Ненормалізована ймовірність No:", prob_no)

# Нормалізація
if prob_yes + prob_no != 0:
    norm_yes = prob_yes / (prob_yes + prob_no)
    norm_no = prob_no / (prob_yes + prob_no)
else:
    norm_yes = 0
    norm_no = 0

print("P(Yes) =", round(norm_yes, 4))
print("P(No) =", round(norm_no, 4))

if norm_yes > norm_no:
    print("Висновок: матч відбудеться.")
else:
    print("Висновок: матч не відбудеться.")

```

Результат виконання завдання

					ЖИТОМИРСЬКА ПОЛІТЕХНІКА.24.125.12.000 –Лр.6	Арк.
						2
Змн.	Арк.	№ докум.	Підпис	Дата		

```
Ненормалізована ймовірність Yes: 0.031746031746031744
Ненормалізована ймовірність No: 0.0
P(Yes) = 1.0
P(No) = 0.0
Висновок: матч відбудеться.
```

Завдання 4. Застосуєте методи байєсівського аналізу до набору даних про ціни на квитки на іспанські високошвидкісні залізниці.

Лістинг код :

```
import pandas as pd
import numpy as np

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from sklearn.naive_bayes import GaussianNB
from sklearn.metrics import classification_report, accuracy_score,
confusion_matrix

url = "https://raw.githubusercontent.com/susanli2016/Machine-Learning-with-Python/master/data/renfe_small.csv"

data = pd.read_csv(url)

print("Перші 5 рядків:")
print(data.head())

print("\nІнформація про датасет:")
print(data.info())

# Видаляємо рядки без ціни
data = data.dropna(subset=["price"])

# Створюємо категорії ціни
data["price_category"] = pd.cut(
    data["price"],
    bins=3,
    labels=["low", "medium", "high"]
)

# Вибираємо ознаки
features = ["origin", "destination", "train_type", "train_class", "fare"]

# Залишаємо тільки потрібні стовпці
data = data[features + ["price_category"]]

# Видаляємо пропущені значення
data = data.dropna()

# Кодування текстових ознак
label_encoders = {}
```

					ЖИТОМИРСЬКА ПОЛІТЕХНІКА.24.125.12.000 –Лр.6	Арк.
						3
Змн.	Арк.	№ докум.	Підпис	Дата		

```

for column in features:
    encoder = LabelEncoder()
    data[column] = encoder.fit_transform(data[column])
    label_encoders[column] = encoder

# Кодування цільової змінної
target_encoder = LabelEncoder()
data["price_category"] = target_encoder.fit_transform(data["price_category"])

X = data[features]
y = data["price_category"]

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, random_state=42
)

model = GaussianNB()
model.fit(X_train, y_train)

y_pred = model.predict(X_test)

print("\nAccuracy:", round(accuracy_score(y_test, y_pred), 4))

print("\nConfusion matrix:")
print(confusion_matrix(y_test, y_pred))

print("\nClassification report:")
print(classification_report(y_test, y_pred, target_names=target_encoder.classes_))

```

Результат виконання

					ЖИТОМИРСЬКА ПОЛІТЕХНІКА.24.125.12.000 –Лр.6	Арк.
						4
Змн.	Арк.	№ докум.	Підпис	Дата		

```
Перші 5 рядків:
   insert_date  origin  ...  train_class  fare
0  2019-04-22 08:00:25  MADRID  ...  Turista  Flexible
1  2019-04-22 10:03:24  MADRID  ...  Turista  Promo
2  2019-04-25 19:19:46  MADRID  ...  Turista  Promo
3  2019-04-24 06:21:57  SEVILLA  ...  Turista con enlace  Promo +
4  2019-04-19 21:13:55  VALENCIA  ...  Turista  Promo
```

```
[5 rows x 9 columns]
```

```
Інформація про датасет:
```

```
<class 'pandas.DataFrame'>
```

```
RangeIndex: 25798 entries, 0 to 25797
```

```
Data columns (total 9 columns):
```

```
#   Column      Non-Null Count  Dtype
---  -
0   insert_date  25798 non-null    str
1   origin       25798 non-null    str
2   destination  25798 non-null    str
3   start_date   25798 non-null    str
4   end_date     25798 non-null    str
5   train_type   25798 non-null    str
6   price        22716 non-null    float64
7   train_class  25695 non-null    str
8   fare         25695 non-null    str
```

```
dtypes: float64(1), str(8)
```

```
memory usage: 1.8 MB
```

```
None
```

```
Accuracy: 0.8479
```

```
Confusion matrix:
```

```
[[ 1  1 29]
 [ 0 3708 750]
 [ 0  84 1106]]
```

```
Classification report:
```

```
precision    recall  f1-score   support

high         1.00      0.03      0.06         31
low          0.98      0.83      0.90        4458
medium       0.59      0.93      0.72        1190

accuracy          0.85         5679
macro avg         0.85      0.60      0.56         5679
weighted avg      0.90      0.85      0.86         5679
```

```
Process finished with exit code 0
```

Висновок : У лабораторній роботі було досліджено застосування теореми Байєса та наївного байєсівського класифікатора. Було розглянуто ручний розрахунок ймовірності проведення матчу залежно від погодних умов, а також реалізовано цей розрахунок у Python. Додатково було застосовано Gaussian Naive Bayes до реального набору даних RENFE. У результаті роботи було встановлено, що наївний Байєс є простим і швидким методом класифікації, який може ефективно застосовуватись для прогнозування на основі ймовірностей.

Посилання на [GitHub](#)

					ЖИТОМИРСЬКА ПОЛІТЕХНІКА.24.125.12.000 –Лр.6	Арк.
						5
Змн.	Арк.	№ докум.	Підпис	Дата		