

Лабораторна робота 7

ДОСЛІДЖЕННЯ МЕТОДІВ НЕКОНТРОЛЬОВАНОГО НАВЧАННЯ

Мета роботи: використовуючи спеціалізовані бібліотеки та мову програмування Python дослідити методи неконтрольованої класифікації даних у машинному навчанні.

Завдання 2.1 — K-Means для data_clustering.txt

Лістинг код :

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans

X = np.loadtxt("data_clustering.txt", delimiter=",")

plt.figure()
plt.scatter(X[:, 0], X[:, 1], marker="o", facecolors="none", edgecolors="black", s=80)
plt.title("Вхідні дані")
plt.grid(True)
plt.show()

num_clusters = 5

kmeans = KMeans(init="k-means++", n_clusters=num_clusters, n_init=10, random_state=0)
kmeans.fit(X)

step_size = 0.01

x_min, x_max = X[:, 0].min() - 1, X[:, 0].max() + 1
y_min, y_max = X[:, 1].min() - 1, X[:, 1].max() + 1

x_vals, y_vals = np.meshgrid(
    np.arange(x_min, x_max, step_size),
    np.arange(y_min, y_max, step_size)
)

output = kmeans.predict(np.c_[x_vals.ravel(), y_vals.ravel()])
output = output.reshape(x_vals.shape)

plt.figure()
plt.imshow(
    output,
    interpolation="nearest",
    extent=(x_vals.min(), x_vals.max(), y_vals.min(), y_vals.max()),
    cmap=plt.cm.Paired,
    aspect="auto",
    origin="lower"
)
```

					ЖИТОМИРСЬКА ПОЛІТЕХНІКА.25.125.12.000 –Лр.7					
Змн.	Арк.	№ докум.	Підпис	Дата						
Розроб.		Лук'яненко В. Я.			Звіт з лабораторної роботи №7			Лім.	Арк.	Акрушів
Перевір.		Маєвський О. В.							1	
Реценз.								ФІКТ, гр. КБ-23-1		
Н. Контр.										
Зав.каф.		Єфіменко А.А.								


```
plt.scatter(X[:, 0], X[:, 1], marker="o", facecolors="none", edgecolors="black",
s=80)

cluster_centers = kmeans.cluster_centers_
plt.scatter(
    cluster_centers[:, 0],
    cluster_centers[:, 1],
    marker="o",
    s=210,
    linewidths=4,
    color="black",
    zorder=12,
    facecolors="black"
)

plt.title("Границі кластерів методом K-Means")
plt.xlim(x_min, x_max)
plt.ylim(y_min, y_max)
plt.grid(True)
plt.show()

print("Центри кластерів:")
print(cluster_centers)
```

Результат виконання



У завданні було виконано кластеризацію двовимірних даних методом K-Means. Було задано кількість кластерів, побудовано модель, визначено центри кластерів і візуалізовано області належності точок до кластерів. Отриманий графік показує, що алгоритм розділив вхідні дані на 5 груп відповідно до їх просторового розташування.

Завдання 2.2 — K-Means для Iris

					ЖИТОМИРСЬКА ПОЛІТЕХНІКА.24.125.12.000 –Лр.7	Арк.
Змн.	Арк.	№ докум.	Підпис	Дата		2

ЛІСТИНГ КОД :

```
import numpy as np
import matplotlib.pyplot as plt

from sklearn.datasets import load_iris
from sklearn.cluster import KMeans
from sklearn.metrics import adjusted_rand_score

iris = load_iris()

X = iris.data
y = iris.target

kmeans = KMeans(n_clusters=3, init="k-means++", n_init=10, random_state=0)

kmeans.fit(X)

labels = kmeans.predict(X)

centers = kmeans.cluster_centers_


plt.figure(figsize=(8, 6))
plt.scatter(X[:, 0], X[:, 1], c=labels, s=50, cmap="viridis")
plt.scatter(centers[:, 0], centers[:, 1], c="black", s=200, alpha=0.7, marker="x")
plt.xlabel("Sepal length")
plt.ylabel("Sepal width")
plt.title("K-Means clustering for Iris dataset")
plt.grid(True)
plt.show()

print("Центри кластерів:")
print(centers)

print("Adjusted Rand Index:")
print(round(adjusted_rand_score(y, labels), 4))
```

Результат виконання

					ЖИТОМИРСЬКА ПОЛІТЕХНІКА.24.125.12.000 –Лр.7	Арк.
						3
Змн.	Арк.	№ докум.	Підпис	Дата		



Центри кластерів:

```
[[5.9016129  2.7483871  4.39354839  1.43387097]
 [5.006      3.428      1.462      0.246      ]
 [6.85       3.07368421  5.74210526  2.07105263]]
```

Adjusted Rand Index:

0.7302

Було виконано кластеризацію набору даних Iris методом К-Means. Алгоритм розділив дані на 3 кластери, що відповідає кількості реальних типів ірисів. Оскільки К-Means працює без використання правильних міток класів, отримані кластери можуть не повністю збігатися з реальними класами, але загальна структура даних добре відображається на графіку.

Завдання 2.3 — Mean Shift

Лістинг код :

```
import numpy as np
import matplotlib.pyplot as plt

from sklearn.cluster import MeanShift, estimate_bandwidth
from itertools import cycle

X = np.loadtxt("data_clustering.txt", delimiter=",")

bandwidth_X = estimate_bandwidth(X, quantile=0.1, n_samples=len(X))

meanshift_model = MeanShift(bandwidth=bandwidth_X, bin_seeding=True)
meanshift_model.fit(X)
```

					ЖИТОМИРСЬКА ПОЛІТЕХНІКА.24.125.12.000 –Лр.7	Арк.
						4
Змн.	Арк.	№ докум.	Підпис	Дата		

```

cluster_centers = meanshift_model.cluster_centers_
labels = meanshift_model.labels_

num_clusters = len(np.unique(labels))

print("Centers of clusters:")
print(cluster_centers)

print("\nNumber of clusters in input data =", num_clusters)

plt.figure()

markers = "oxvs"

for i, marker in zip(range(num_clusters), cycle(markers)):
    plt.scatter(
        X[labels == i, 0],
        X[labels == i, 1],
        marker=marker,
        color="black"
    )


    cluster_center = cluster_centers[i]
    plt.plot(
        cluster_center[0],
        cluster_center[1],
        marker="o",
        markerfacecolor="black",
        markeredgecolor="black",
        markersize=15
    )

plt.title("Кластери методом Mean Shift")
plt.grid(True)
plt.show()

```

Результат виконання

					ЖИТОМИРСЬКА ПОЛІТЕХНІКА.24.125.12.000 –Лр.7	Арк.
						5
Змн.	Арк.	№ докум.	Підпис	Дата		



У завданні було застосовано алгоритм Mean Shift для оцінки кількості кластерів у наборі даних. На відміну від K-Means, цей метод не потребує попереднього задання кількості кластерів. Після навчання модель автоматично визначила центри кластерів і кількість груп у даних. Отриманий результат залежить від параметра bandwidth.

Завдання 2.4 — Affinity Propagation

Це завдання в методичці старе: там використовується завантаження біржових даних із matplotlib, яке в нових версіях Python часто не працює. Тому буду використовувати робочий сучасний варіант на штучних даних фондових змін.

Лістинг код :

```
import numpy as np
from sklearn.cluster import AffinityPropagation
from sklearn.preprocessing import StandardScaler

companies = np.array([
    "Apple", "Microsoft", "Google", "Amazon", "Meta",
    "Tesla", "Ford", "General Motors",
    "JPMorgan", "Bank of America", "Citigroup",
    "ExxonMobil", "Chevron"
])

np.random.seed(42)

tech = np.random.normal(loc=0.8, scale=0.2, size=(5, 10))
auto = np.random.normal(loc=-0.2, scale=0.2, size=(3, 10))
banks = np.random.normal(loc=0.2, scale=0.2, size=(3, 10))
energy = np.random.normal(loc=0.5, scale=0.2, size=(2, 10))
```

```
X = np.vstack([tech, auto, banks, energy])
X = StandardScaler().fit_transform(X)
model = AffinityPropagation(random_state=0)
model.fit(X)
labels = model.labels_
num_clusters = len(np.unique(labels))
print("Number of clusters:", num_clusters)
for i in range(num_clusters):
    print("Cluster", i + 1, "=>", ", ".join(companies[labels == i]))
```

Результат виконання

```
Number of clusters: 3
Cluster 1 => Apple, Microsoft, Google, Amazon, Meta, ExxonMobil, Chevron
Cluster 2 => Tesla, Ford, General Motors
Cluster 3 => JPMorgan, Bank of America, Citigroup
```

У завданні було використано алгоритм Affinity Propagation для пошуку підгруп серед компаній фондового ринку. Алгоритм виконав кластеризацію на основі подібності змін котирувань. На відміну від K-Means, Affinity Propagation не потребує попереднього задання кількості кластерів, а самостійно визначає представницькі елементи груп. Отримані кластери відображають компанії з подібною поведінкою фінансових показників.

Висновок : Я використав спеціалізовані бібліотеки та мову програмування Python дослідив методи неконтрольованої класифікації даних у машинному навчанні.

Посилання на [GitHub](#)

					ЖИТОМИРСЬКА ПОЛІТЕХНІКА.24.125.12.000 –Лр.7	Арк.
						7
Змн.	Арк.	№ докум.	Підпис	Дата		